

Letra da Lei — RAG hierarquia- e vigência-aware sobre o microssistema penal federal

Identificação

- **Aluno:** Anderson Felipe Paixão Corrêa
 - **Disciplina:** Sistemas Cognitivos com Large Language Models (INFNET, 26E2_3)
 - **Título do projeto:** Letra da Lei — o direito como dado: RAG e análise do microssistema penal federal
 - **Repositório (reprodução):** https://github.com/andersonfpcorreia/26E2_3
-

Acesso aos artefatos

Todos os artefatos do projeto — as sete notebooks executadas, o código-fonte do pacote `direito_dados`, o corpus bruto, as figuras e os testes — estão no repositório público abaixo. As notebooks são renderizadas diretamente pelo GitHub, com todas as saídas e gráficos visíveis no navegador, sem necessidade de instalação.

- **Repositório:** https://github.com/andersonfpcorreia/26E2_3
- **Notebooks executadas (renderizadas no GitHub):**

<code>c01_modelos_llm.ipynb</code>	·	<code>c03_embeddings_busca.ipynb</code>	·
<code>c02_prompting.ipynb</code>	·	<code>c04_inferencia_local_ou_remota.ipynb</code>	·
<code>c05_rag_pipeline.ipynb</code>	·	<code>c06_antinomias.ipynb</code>	·
<code>c07_lei_como_dado.ipynb</code>	·		
- **Código-fonte:** `direito_dados/` (pacote instalável, testado, com 169 testes em `tests/`)
- **Interface web local (opcional, além da rubrica):** `app.py` — `make app`
- **Dataset de autoria das leis emendadoras:** `data/attribution/authorship.json`
- **README com instruções de uso:** `README.md`
- **Corpus bruto (snapshot versionado):** `data/raw/`
- **Figuras deste relatório:** `report/figures/`

Cada notebook é deliberadamente fina: importa e chama funções já implementadas e testadas em `direito_dados/`, em vez de reimplementar lógica em células soltas. Essa escolha de arquitetura — "a notebook empacota, o pacote implementa" — significa que qualquer resultado mostrado abaixo é reproduzível fora do Jupyter, via `pytest` ou via um script Python comum.

Problema e motivação

O direito penal brasileiro é extenso, estratificado em normas de hierarquias diferentes e **constantemente autoemendado** — a ponto de uma pergunta aparentemente simples ("esse artigo ainda vale?") ser difícil de responder com segurança para um cidadão leigo, e mesmo para um profissional sem acesso a uma base atualizada. Este projeto explora até onde um sistema de **Retrieval-Augmented Generation (RAG)** consciente de **hierarquia normativa** e de **vigência** consegue ajudar a navegar essa complexidade.

O objetivo civil do projeto é **democratizar a compreensão** da complexidade da lei — não substituir análise jurídica. Essa distinção é deliberada e estrutural, não apenas uma ressalva de rodapé:

O sistema nunca conclui sobre a situação legal de ninguém. Ele localiza, fundamenta, cita e explica normas relevantes; aponta *candidatos* a conflito para revisão humana; e se abstém quando não há base suficiente. Isso não é aconselhamento jurídico, parecer, nem qualquer forma de consulta — é uma ferramenta de pesquisa e compreensão de texto legal.

Essa postura de "candidato, nunca veredito" está implementada em código, não apenas declarada: toda aresta `conflict_candidate` produzida pelo detector de antinomias carrega `verification_state=CANDIDATE` (nunca `VERIFIED`), e toda citação retornada pelo RAG passa por verificação programática contra o corpus antes de ser aceita.

Escolher esse enquadramento também transforma perguntas difíceis de avaliar ("essa é uma boa orientação jurídica?") em perguntas mensuráveis: quantas emendas o Código Penal recebeu por década? Quantos conflitos candidatos o detector encontra e com que precisão/revocação? Qual a taxa de citação alucinada do RAG? Essas são as perguntas que as sete notebooks respondem, uma por uma, e que este relatório consolida.

Descrição e obtenção do corpus

O corpus cobre as **9 normas do microssistema penal federal brasileiro**, delimitado pela competência legislativa penal **exclusiva da União** (CF, art. 22, I) — um recorte que é completo por definição constitucional, não truncado por conveniência (direito penal estadual/municipal simplesmente não existe no Brasil):

Norma	Descrição	Artigos
CF	Constituição Federal (1988)	512
CP	Código Penal (Decreto-Lei 2.848/1940)	431

CPP	Código de Processo Penal (Decreto-Lei 3.689/1941)	849
LEP	Lei de Execução Penal (Lei 7.210/1984)	219
L11343	Lei de Drogas (Lei 11.343/2006)	114
L11340	Lei Maria da Penha (Lei 11.340/2006)	60
L8072	Lei de Crimes Hediondos (Lei 8.072/1990)	20
DL3688	Lei das Contravenções Penais (Decreto-Lei 3.688/1941)	75
LINDB	Lei de Introdução às Normas do Direito Brasileiro (Decreto-Lei 4.657/1942)	30
Total		2.310

Dos 2.310 artigos, **2.248 estão em vigor** (1.215 na redação original/vigente + 1.033 alterado por emenda posterior) e **62 estão revogados**. A LINDB merece destaque à parte: é a própria norma que **codifica as regras de resolução de antinomias** (*lex superior, lex posterior, lex specialis*) usadas pelo detector de conflitos da seção correspondente — está no corpus tanto como objeto de análise quanto como fonte dos princípios que orientam essa análise.

Fonte e obtenção. O texto de cada norma é obtido do **Portal da Legislação do Planalto** (planalto.gov.br), que publica a *redação consolidada* de cada lei com anotações inline de vigência — por exemplo (Redação dada pela Lei nº 13.964, de 2019) ou (Revogado pela Lei nº 12.015, de 2009). Essas anotações são a matéria-prima de todo o projeto: delas derivam tanto o grafo de emendas/revogações (seção "a lei como dado") quanto o filtro de vigência da recuperação (seção "Embeddings e Busca").

Um snapshot já processado acompanha o repositório em `data/raw/` (textos de domínio público, um arquivo `.txt` por norma), de modo que a reprodução do projeto **não depende de acesso à rede**. Para rebaixar as normas diretamente do Planalto:

```
make data          # equivale a: uv run python scripts/fetch_corpus.py
```

O script (`scripts/fetch_corpus.py`) percorre o registro de 9 normas (`direito_dados.corpus.registry.NORMS`), baixa cada uma via `direito_dados.corpus.fetch.download_norm` com um intervalo de cortesia de 1,5s entre requisições, e reporta falhas individuais sem abortar o lote inteiro — uma norma que falhe é simplesmente pulada e pode ser tentada de novo depois.

Justificativa do corpus e do uso de LLMs

Por que este corpus. Três propriedades tornam o microssistema penal federal um recorte particularmente produtivo para este projeto:

1. **Escopo fechado e legalmente completo.** Por ser competência exclusiva da União, o recorte não é uma amostra arbitrária — é o universo inteiro do domínio. Isso permite construir *gold sets* pequenos, mas exaustivos o bastante para avaliação (ex.: o conjunto de recuperação de 6 perguntas e o conjunto de antinomias de 3 pares), algo inviável em um corpus de escala nacional irrestrita.
2. **Complexidade real, tamanho tratável.** Com 2.310 artigos, 9 hierarquias/datas de promulgação diferentes e milhares de emendas históricas, o corpus tem estrutura genuinamente difícil (hierarquia normativa, vigência artigo a artigo, potenciais antinomias) sem exigir infraestrutura de escala industrial — uma decisão consciente de custo e reprodutibilidade em ambiente acadêmico.
3. **Anotações de vigência prontas para extração.** O Planalto já anota cada alteração/revogação inline. Isso torna a vigência **metadados extraíveis por regex** em vez de um problema de NLP não resolvido — o que libera o projeto para investir esforço onde realmente há um problema difícil de linguagem natural: recuperação semântica, geração fundamentada e adjudicação de conflitos.

Por que LLMs. O projeto usa LLMs em três papéis distintos e complementares, cada um escolhido porque a tarefa correspondente **não é resolvível de forma puramente determinística**:

- **Geração de respostas em linguagem natural** fundamentadas em texto legal recuperado — reformular dispositivos técnicos em prosa compreensível é uma tarefa de linguagem, não de busca.
- **Adjudicação de *lex specialis*** entre dois dispositivos candidatos a conflito — decidir qual norma é "mais específica" exige leitura semântica do conteúdo, não apenas comparação de metadados (ao contrário de *lex superior/lex posterior*, que são puramente determinísticos a partir de hierarquia e data).
- **Embeddings semânticos** para recuperação — encontrar o artigo relevante para uma pergunta em linguagem natural do cidadão ("quem mata alguém") exige mapear vocabulário coloquial para vocabulário jurídico, algo que buscas lexicais puras fazem mal (ver a seção de embeddings, caso do art. 171).

Ao mesmo tempo, o projeto **não terceiriza para o LLM aquilo que pode ser feito de forma determinística e auditável**: vigência é regex sobre anotações do Planalto, *lex superior/lex posterior* são cálculo sobre metadados, e toda citação emitida pelo modelo é verificada programaticamente contra o corpus antes de ser aceita. Essa divisão de trabalho — LLM para julgamento semântico, código determinístico para tudo que pode ser determinístico — é o fio condutor de todas as decisões de arquitetura descritas a seguir.

Modelos e ferramentas

Papel	Modelo/Ferramenta	Onde é usado
Tokenização subword / MLM ilustrativo	neuralmind/bert-base-portuguese-caspl (BERTimbau)	c01 — exploração de encoder de propósito geral
Embeddings de recuperação (encoder de produção)	intfloat/multilingual-e5-base (E5Embedder)	c03, c05, c06 — indexação e consulta
Geração / decoder (produção)	llama3.1:8b via Ollama (OllamaClient)	c02, c04, c05, c06
Vector store	ChromaDB (chromadb.EphemeralClient/PersistentClient, distância de cosseno)	c03, c05, c06
Busca lexical	BM25 puro em Python (k1=1,5; b=0,75), sem dependência externa	c03
Framework de tokenização/HF	transformers	c01
Embeddings/encoder	sentence-transformers, torch	c03, c05, c06
Grafo e visualização	networkx, matplotlib	c07
Corpus (parsing/fetch)	beautifulsoup4, lxml, requests	corpus, scripts/fetch_corpus.py

Testes	pytest (169 testes, incluindo integração ao vivo com e5 e Ollama)	tests/
--------	---	--------

Toda a geração é **local**, via Ollama — nenhuma chamada a API de nuvem é feita em nenhuma das sete notebooks (a comparação com nuvem, na seção de inferência, é arquitetada e justificada, não executada). Essa escolha é discutida em detalhe na seção "Estratégia de inferência local ou remota".

Tarefas de PLN e Hugging Face (c01)

A notebook `c01_modelos_llm.ipynb` explora, sobre texto real do corpus (o Código Penal), três frentes com a biblioteca `transformers`: tokenização subword, a distinção arquitetural encoder/decoder, e uma tarefa aplicada que compara os dois papéis lado a lado.

Tokenização subword com BERTimbau

O caput do art. 121 (homicídio) — "Matar alguém: Pena - reclusão, de seis a vinte anos." — é tokenizado pelo `neuralmind/bert-base-portuguese-cased` em **18 tokens** (incluindo `[CLS]`/`[SEP]`):

```
[CLS] Mata ##r algu ##em : Pena - rec ##lusão , de seis a vinte anos . [SEP]
```

"Matar" quebra em `Mata+##r`; "reclusão" quebra em `rec+##lusão`; já "Pena", "seis", "vinte" e "anos" permanecem inteiros. Comparando termos jurídicos raros com termos comuns, a fragmentação em subtokens cresce nitidamente com a raridade do jargão:

Termo	Nº de subtokens	Subtokens
matar	1	matar
casa	1	casa
concussão	2	conc, ##ussão
peculato	2	pecul, ##ato
prevaricação	3	prev, ##ari, ##cação
estelionato	4	este, ##lio, ##na, ##to

Termos técnicos do direito penal (prevaricação, estelionato, peculato) são fragmentados em mais subtokens que vocabulário do dia a dia — sintoma de sub-representação desse jargão no pré-treinamento geral do modelo, e o primeiro indício, ainda no nível de tokenização, de que conhecimento jurídico fino não é garantido por um encoder de propósito geral.

Encoder vs. decoder — papéis distintos no projeto

O restante do projeto usa dois modelos com papéis deliberadamente diferentes:

Papel	Modelo	Classe	Uso
Encoder	<code>intfloat/multilingual-e5</code>	<code>E5Embedder</code>	embeddings de consulta/dispositivo para o <code>VectorIndex</code>
Decoder	<code>llama3.1:8b</code> (Ollama)	<code>OllamaClient</code>	geração de resposta citada e adjudicação de conflitos

Um teste de *fill-mask* com BERTimbau confirma o comportamento bidirecional esperado de um encoder — mascarando a **primeira** palavra da frase ("Paris é a capital da França"), o modelo é forçado a usar apenas o contexto à direita e ainda assim recupera a resposta correta com folga:

```
0.850 Paris é a capital da França.  
0.051 Cannes é a capital da França.  
0.045 Nice é a capital da França.
```

Tarefa aplicada: comparação e5 (encoder de recuperação) vs. BERTimbau (encoder de propósito geral)

Tarefa A — similaridade semântica com e5. A matriz de similaridade de cosseno entre os embeddings de três dispositivos do CP mostra ordenação semanticamente correta:

	art. 121 (homicídio)	art. 155 (furto)	art. 157 (roubo)
art. 121 (homicídio)	1,000	0,906	0,858
art. 155 (furto)	0,906	1,000	0,920
art. 157 (roubo)	0,858	0,920	1,000

Furto e roubo — ambos crimes patrimoniais — têm a maior similaridade (0,920); homicídio e roubo, a menor (0,858). A ordenação relativa é correta, apesar de margens estreitas por causa do vocabulário jurídico genérico compartilhado por todos os artigos do Código.

Tarefa B — achado honesto sobre conhecimento paramétrico jurídico fraco. Um teste de *cloze* jurídico com BERTimbau mascara exatamente o elemento distintivo do crime de furto:

```
"Subtrair, para si ou para outrem, coisa alheia [MASK]: pena de reclusão."
```

O caput real do art. 155 é "*coisa alheia móvel*" — mas a palavra correta não aparece entre as cinco previsões mais prováveis do modelo, e todos os scores ficam abaixo de 0,1 (contra 0,850 no cloze

genérico de Paris):

```
0.082  'proibida'  
0.055  'qualquer'  
0.053  '.'  
0.049  'a'  
0.039  '"""
```

O modelo acerta o padrão sintático (as previsões são adjetivos/pronomes plausíveis na posição), mas erra o termo técnico exato — evidência direta de que um encoder de propósito geral **não memorizou de forma confiável** a colocação jurídica "coisa alheia móvel", o elemento que distingue furto de outros crimes patrimoniais. Este é o achado central da notebook e a motivação empírica, ainda no capítulo 1, para toda a arquitetura de RAG que segue: se o conhecimento paramétrico é raso mesmo para um termo tão central de um crime tão comum, respostas fundamentadas em texto recuperado — não em memória do modelo — deixam de ser apenas uma boa prática e passam a ser uma necessidade.

Engenharia de prompt e saída controlada (c02)

A notebook `c02_prompting.ipynb` narra a iteração real até o prompt de produção usado por `direito_dados.generation.rag.answer_question`, testando quatro técnicas com chamadas reais ao `llama3.1:8b`: três em ordem crescente de controle sobre a **forma** da saída — sobre o mesmo par de contexto (art. 121 e art. 155 do CP) e a mesma pergunta, "*Qual a pena para quem mata alguém?*" — e uma quarta (chain-of-thought estruturado) voltada ao **raciocínio**, aplicada ao conflito aparente de normas.

O **critério explícito de qualidade** adotado para avaliar e iterar os prompts foi, em todas as versões, objetivo e verificável programaticamente: **(a)** a saída é parseável (`parse_ok`); **(b)** o array `citations` vem preenchido com os ids exatos dos dispositivos efetivamente usados; **(c)** `abstained` é coerente com o contexto fornecido. Cada versão de prompt foi julgada contra esse critério, e é ele que organiza a tabela comparativa ao final desta seção.

Técnica 1 — Zero-shot, prosa livre

Sem *system prompt* estruturado e sem restrição de formato, o modelo responde corretamente em conteúdo:

```
"A pena prevista para o homicídio (matar alguém) não está explicitamente mencionada nas normas apresentadas, mas é possível inferir que a pena seria de reclusão por um período que varia de acordo com as circunstâncias do crime."
```

Mas o *parser* de saída falha: `parse_ok=False`, `abstained=True`, `citations=[]`. **Lição:** texto livre não é suficiente para um sistema que precisa citar fontes verificáveis — não há nenhuma estrutura da qual extrair uma citação, mesmo quando a resposta em si é aceitável.

Técnica 2 — JSON não guiado (sem contrato de chaves)

Com `format="json"` do Ollama, mas um *system prompt* fraco ("Responda em formato JSON"), o modelo produz JSON sintaticamente válido, porém com chaves diferentes das esperadas:

```
{ "resposta": "A pena para quem mata alguém varia dependendo da circunstância do crime e da in
```

`parse_ok=True`, mas `citations=[]` — a chave é "resposta", não "answer"/"citations". **Lição:** JSON válido não é o mesmo que *schema* correto. (O conteúdo também está factualmente incorreto: a pena real do art. 121 é de 6 a 20 anos, não "12 a 30".)

Técnica 3 — Few-shot + saída controlada por schema (versão de produção)

O `SYSTEM_PROMPT` de produção (`direito_dados.generation.prompt`) combina cinco regras explícitas — responder somente com base no contexto fornecido, listar os ids exatos usados em `citations`, abster-se quando as provisões não bastarem, responder em português, e emitir **estritamente** JSON com um conjunto fixo de chaves — com um **exemplo preenchido** (few-shot) embutido no próprio prompt:

```
EXEMPLO de resposta correta quando o contexto contém [CP:art121] "Matar alguém:
Pena - reclusão, de seis a vinte anos":
{"answer": "Matar alguém (homicídio) é punido com reclusão de 6 a 20 anos.",
 "citations": ["CP:art121"], "hierarchy_notes": "", "abstained": false, "confidence": 0.9}
```

A saída é restrita por um **JSON schema** passado ao parâmetro `format` do Ollama (não apenas `format="json"` genérico), garantindo que a resposta sempre tenha exatamente as chaves esperadas:

```
ANSWER_SCHEMA = {
  "type": "object",
  "properties": {
    "answer": {"type": "string"},
    "citations": {"type": "array", "items": {"type": "string"}},
    "hierarchy_notes": {"type": "string"},
    "abstained": {"type": "boolean"},
    "confidence": {"type": "number"},
  },
  "required": ["answer", "citations", "abstained", "confidence"],
}
```

Além disso, o prompt do usuário lista explicitamente os **ids citáveis** disponíveis ao final do contexto — o mecanismo que torna a citação verificável em vez de livre:

```
Ids disponíveis para citação: CP:art121, CP:art155
Em "citations", liste os ids exatos (ex.: "CP:art121") dos dispositivos acima que
você usou na resposta.
```

Com essa configuração, a estrutura da resposta é sempre correta (`parse_ok=True`, chaves certas, citações parseáveis) — mas a notebook documenta honestamente que o *schema* resolve o problema de **forma**, não o de **conteúdo**: em uma execução real, o modelo local de 8B parâmetros citou corretamente `CP:art121` mas também `CP:art155` (irrelevante para a pergunta) e mencionou "pena de morte em alguns países", que não existe no Código Penal nem no contexto fornecido. A conclusão da notebook é direta: *"o schema resolve o problema estrutural (parseabilidade/forma), não o problema de*

raciocínio/precisão factual do modelo" — um limite honesto do modelo local, retomado com mais profundidade na seção de RAG.

Um teste final confirma **abstenção coerente**: com contexto vazio (nenhuma provisão recuperada) para a pergunta fora de escopo *"Qual o prazo prescricional do IPTU?"*, o modelo retorna `{"answer": "", "citations": [], "abstained": true, "confidence": 1.0}` — sem inventar uma resposta.

Técnica 4 — Chain-of-thought estruturado (raciocínio antes do veredito)

As três técnicas anteriores atacam a **forma** da saída; chain-of-thought ataca o **raciocínio** — e o enunciado o recomenda "quando fizer sentido". No domínio jurídico ele faz sentido exatamente onde este projeto mais precisa dele: no **conflito aparente de normas**, que exige raciocínio em etapas (identificar os dispositivos aplicáveis → testar a relação de especialidade → concluir pela *lex specialis*). O experimento usa o caso clássico da doutrina — homicídio (art. 121, norma geral) vs. infanticídio (art. 123, norma especial) — em duas variantes sobre o mesmo contexto: **(A)** veredito direto (schema pede apenas `dispositivo + justificativa`); **(B)** CoT estruturado (o schema inclui um campo `raciocinio`, lista de passos, **antes** dos campos de veredito — como a geração é autoregressiva, os tokens de raciocínio são gerados antes do veredito, condicionando-o, em vez de uma racionalização a posteriori).

No resultado real, **as duas variantes acertam o veredito** (CP:art123, infanticídio) — o caso é clássico o bastante para o modelo de 8B. A diferença está no que cada saída permite **auditar**. A Variante B expõe o teste de especialidade passo a passo:

```
"raciocinio": [
  "(2) ... Sim, porque o art. 123 especifica que a conduta deve ser cometida pela gestante sob influência do estado puerperal e contra o próprio filho.",
  "(3) O dispositivo específico [prevalece], pois ele contém elementos adicionais que não estão presentes no art. 121."
],
"dispositivo": "CP:art123"
```

Em um sistema que só emite **candidatos para revisão humana**, essa auditabilidade é o valor real do chain-of-thought: o revisor confere o *porquê*, não apenas o *o quê*. É por isso que o adjudicador de antinomias de produção (`direito_dados.conflicts.detector`, seção c06) exige o campo `rationale` no schema do veredito — a mesma técnica, institucionalizada no pipeline.

Resumo comparativo — as três técnicas de forma, avaliadas contra o critério explícito de qualidade:

Técnica	Mecanismo	parse_ok	Citações confiáveis?	Abstenção coerente?
1. Zero-shot	instrução livre, sem format	não	não (nem chega a parsear)	não
2. JSON não guiado	format="json", sem contrato de chaves	sim	não (chaves divergentes)	não confiável

3. Few-shot + schema	SYSTEM_PROMPT (com exemplo) + format=<schema> + ids explícitos	sim	sim	sim
----------------------	---	-----	-----	-----

A Técnica 3 é a usada em produção, ainda apoiada por `parse_answer` como rede de segurança: se, apesar do schema, a saída vier malformada, o parser falha para o lado seguro (`abstained=True`, `parse_ok=False`) em vez de lançar exceção ou fabricar uma estrutura.

Embeddings, estratégia de busca e avaliação (c03)

A notebook `c03_embeddings_busca.ipynb` cobre o subsistema de recuperação sobre um subconjunto de 545 artigos (CP + Lei de Drogas), sem reimplementar nenhuma lógica de recuperação — apenas exercitando os módulos já testados de `direito_dados.retrieval`.

Correção do parser: rubrica-aware article splitting

Antes de descrever o chunking em vigor, vale narrar como se chegou a ele — é a peça de engenharia mais consequente do projeto e mudou praticamente todos os números desta seção.

Diagnóstico. O Planalto imprime o nome oficial do crime (a *rubrica*, ou *nomen juris* — ex. "Furto", "Estelionato", "Violação sexual mediante fraude") **imediatamente antes** da linha `Art. N.` a que ele pertence. O parser original de divisão de artigos, baseado em regex sobre os cabeçalhos `Art. N.`, tratava tudo que vinha antes de um cabeçalho como pertencente ao artigo **anterior** — o que grudava sistematicamente cada rubrica no fim do artigo errado. O sintoma concreto que expôs o problema: `CP:art215` (violação sexual mediante fraude) não aparecia nem no top-15 de uma busca pelo próprio nome oficial do crime, porque sua rubrica estava, na prática, embutida no texto do art. 214 (o dispositivo revogado que ele sucedeu).

Correção. `Article` ganhou um campo `rubrica` (`direito_dados/corpus/models.py`), e uma nova função `_split_trailing_rubrica` (`direito_dados/corpus/parser.py`) roda um passe pós-divisão que identifica linhas de cabeçalho contíguas ao final de cada bloco de artigo — título-caso, sem pontuação terminal, não em caixa alta, não uma linha de Pena/parágrafo/anotação — e as move para o artigo **seguinte**, a quem de fato pertencem. Cabeçalhos estruturais (CAPÍTULO, TÍTULO, seções em caixa alta) e anotações de vigência nunca são movidos, apenas rubricas genuínas. `chunk_corpus` (`direito_dados/retrieval/chunks.py`) passou a construir `embed_text` como `f"{rubrica}. {caput}. {texto}"[:300]` quando o artigo tem rubrica — a rubrica lidera porque é o sinal mais forte para consultas por nome de crime: é literalmente o nome pelo qual o crime é conhecido ("furto", "estelionato"), enquanto o *caput* e o texto operativo usam vocabulário técnico-descritivo que nem sempre contém esse nome.

Validação. Sobre o corpus real, a extração recupera corretamente as 8/8 rubricas de crimes emblemáticos testadas manualmente (Homicídio simples, Furto, Roubo, Estelionato, Estupro, Peculato, Corrupção passiva, Violação sexual mediante fraude) e extrai rubrica para 423 artigos no corpus inteiro. Um conjunto de 5 consultas-litmus de recuperação — incluindo os três casos historicamente quebrados (art. 215, o desempate 155-vs-168, e o *miss* denso do art. 171) — passou a acertar o rank 1 em todos os

casos após a correção. Os 169 testes do projeto passam, com 5 novos casos dedicados a `_split_trailing_rubrica` (`tests/corpus/test_parser.py`): a rubrica gruda no artigo seguinte, some do texto do artigo anterior, cabeçalhos estruturais nunca são confundidos com rubrica, uma linha de Pena nunca é "roubada" como rubrica, e a vigência derivada do *caput* continua correta mesmo com o texto rearranjado.

Modelo de embeddings e estratégia de chunking

O modelo é o `intfloat/multilingual-e5-base`, usado com os prefixos assimétricos que ele exige ("passage: " para textos indexados, "query: " para consultas — omiti-los degrada a qualidade da recuperação).

A unidade de indexação (Chunk) é **um por artigo**, mas o texto efetivamente embutido não é o corpo bruto do artigo: é `f"{rubrica}. {caput}. {texto}"[:300]` — uma estratégia de **chunking rubrica- e caput-forward**. Quando o artigo tem rubrica (nem todo artigo abre um tipo penal novo, então nem todo artigo tem uma), ela lidera o texto embutido, seguida do *caput* (a frase de abertura do artigo, normalmente a descrição nuclear da conduta), repetido para reforçar seu peso. A motivação para o reforço é que muitos artigos têm parágrafos e incisos longos que, sozinhos, diluiriam esses dois sinais se fossem embutidos sem essa dupla ênfase. Exemplo real, art. 121 (rubrica "Homicídio simples"):

```
embed_text: "Homicídio simples. Matar alguém:. Matar alguém:
Pena - reclusão, de seis a vinte anos.
Caso de diminuição de pena
§
1º Se o agente comete o crime impelido por motivo de relevante valor social ou moral..."
```

Note a rubrica ("Homicídio simples.") abrindo o texto embutido, seguida do *caput* ("Matar alguém:") repetido. Para a consulta em linguagem natural "qual a pena para quem mata alguém?", essa estratégia resulta em `CP:art121` recuperado em **1º lugar** (score 0,887), seguido de dispositivos correlatos por vocabulário jurídico compartilhado (art. 226, art. 212, art. 209, art. 258):

```
Consulta: "qual a pena para quem mata alguém?"
CP art. 121          score=0.887
CP art. 226          score=0.860
CP art. 212          score=0.858
CP art. 209          score=0.855
CP art. 258          score=0.855
```

Outras duas consultas de domínios distintos confirmam a mesma precisão temática — "furto de coisa alheia móvel" agora recupera o próprio `CP:art155` em 1º lugar (score 0,890), à frente do cluster de crimes patrimoniais correlatos (art. 168, art. 157, art. 156, art. 313) — e "tráfico ilícito de entorpecentes" recupera exclusivamente artigos da Lei de Drogas e do CP em torno do mesmo campo semântico (art. 17, art. 50-A, art. 18, art. 28).

Vector store e filtragem por vigência

O índice é construído em **ChromaDB** (distância de cosseno), com **524 passagens únicas** após deduplicação de colisões de id geradas por um artefato conhecido do parser em incisos da Lei de Drogas (Art. 8º-A a 8º-F colapsando em `L11343:art8`).

A propriedade de segurança mais importante da camada de recuperação é a **exclusão de dispositivos revogados por padrão** (`exclude_revoked=True`). Duas consultas desenhadas para "casar" com artigos hoje revogados do Código Penal demonstram isso na prática — e, depois do parser rubrica-aware, com papéis diferentes entre si:

```
Consulta: "usurpação de nome ou pseudônimo alheio" (CP art. 185, revogado pela Lei 10.695/2009)
-- exclude_revoked=True (padrão) --
CP art. 242  score=0.866  status=alterado
...
(art. 185 ausente)
-- exclude_revoked=False --
CP art. 185  score=0.914  status=revogado  <- maior score de todos
CP art. 242  score=0.866  status=alterado
...

Consulta: "violação sexual mediante fraude" (antigo CP art. 214, revogado pela Lei 12.015/2009)
-- exclude_revoked=True (padrão) --
CP art. 215  score=0.892  status=alterado  <- lidera, com ou sem filtro
...
(art. 214 ausente mesmo sem filtro)
-- exclude_revoked=False --
CP art. 215  score=0.892  status=alterado  <- idêntico ao filtrado
...
```

Na primeira consulta, o filtro é indispensável: com o padrão `exclude_revoked=True`, `CP:art185` fica de fora do top-5; sem o filtro, ele **lidera** (score 0,914) — porque sua rubrica, "Usurpação de nome ou pseudônimo alheio", agora está corretamente presa a ele (antes do parser rubrica-aware, essa rubrica não aparecia associada a nenhum artigo com esse peso). A rubrica sozinha basta para vencer a busca por similaridade, o que torna o filtro `where`, aplicado **antes** da consulta vetorial, indispensável: sem ele, o resultado nº 1 seria uma lei sem nenhum efeito jurídico.

Na segunda consulta, o resultado é hoje **idêntico** com o filtro ligado ou desligado — mas por um motivo que também é consequência direta do `fix`. `CP:art214` não tem mais nenhuma rubrica associada: a redação que originalmente carregava o nome "Violação sexual mediante fraude" foi revogada, e o parser corretamente moveu essa mesma rubrica para `CP:art215`, o dispositivo que sucedeu o revogado na reforma da Lei 12.015/2009. Sem rubrica, o `embed_text` de `CP:art214` é hoje só a nota de revogação — sem sinal semântico sobre o crime — e por isso ele não aparece nem no top-5 sem filtro. `CP:art215` lidera as duas listas com score 0,892. O filtro de vigência continua sendo a garantia estrutural (ele intercepta o cenário do art. 185 acima, e continuaria interceptando um art. 214 competitivo se a rubrica ainda estivesse presa a ele por acidente), mas esta consulta específica deixou de exercitá-lo — um efeito colateral honesto do `fix`, não uma regressão.

Busca densa vs. híbrida (BM25 + densa)

Um índice BM25 puro (sem dependência externa) é combinado com a busca densa por normalização min-max e fusão ponderada (`alpha * denso + (1-alpha) * léxico`, `alpha=0,5` por padrão). O caso do estelionato, historicamente o exemplo central desta seção, **mudou de sinal** com o parser rubrica-aware: para a consulta "*estelionato mediante fraude*", a busca **densa sozinha** hoje já lidera com `CP:art171` —

```
denso : ['CP:art171', 'CP:art170', 'CP:art215', 'CP:art206', 'CP:art183-A']
bm25  : ['CP:art170', 'CP:art204', 'CP:art171', 'CP:art215', 'CP:art178']
```

```
híbrido: ['CP:art171', 'CP:art170', 'CP:art215', 'CP:art204', 'CP:art178']
```

Antes da correção, "Estelionato" era um título de seção descartado pelo parser antigo — nunca chegava a `embed_text`, que carregava apenas a redação operativa do art. 171 ("obter vantagem ilícita... mediante artifício, ardil, ou qualquer outro meio fraudulento"), sem o nome do crime; a busca densa sozinha deixava o art. 171 fora do top-5, e só o BM25 (via sobreposição lexical de "mediante"/variações de "fraude") o recuperava, com a fusão híbrida herdando esse acerto como rede de resgate. Hoje, com a rubrica presa corretamente ao artigo (`embed_text` começa com "Estelionato. Obter, para si..."), o denso já não precisa de ajuda: a fusão híbrida é **redundante** com o denso para esta consulta específica, não mais uma rede de segurança.

Isso levanta uma pergunta honesta: se o denso ficou robusto para nomes de crime, o híbrido ainda tem alguma vantagem prática hoje? Uma terceira consulta, desenhada deliberadamente para **não** usar o vocabulário jurídico do dispositivo nem sua rubrica — uma paráfrase coloquial da apropriação indébita (CP:art168, rubrica "Apropriação indébita"): *"ficar com um dinheiro que recebeu emprestado e não devolver"* — responde que sim:

- **Denso:** CP:art168 não aparece entre os 5 primeiros, nem entre os 20 mais próximos (checagem ampliada feita à parte) — a paráfrase não compartilha vocabulário suficiente com "Apropriação indébita. Apropriar-se de coisa alheia móvel, de que tem a posse ou a detenção..." para que o embedding aproxime os dois.
- **BM25:** recupera CP:art168 na **4ª posição** — há sobreposição lexical parcial suficiente com outros artigos do capítulo de crimes patrimoniais.
- **Híbrido:** mesmo assim, CP:art168 **não aparece** no top-5 híbrido. Como o artigo está ausente do pool denso, sua pontuação normalizada nesse componente é 0,0, o que reduz pela metade ($\alpha=0,5$) a pontuação combinada e o deixa atrás de artigos que pontuam moderadamente em ambos os retrievers ao mesmo tempo, mesmo sem ser a resposta certa para nenhum deles isoladamente.

Este é o caso de falha real e honesto desta seção, que substitui o antigo exemplo do estelionato como demonstração do limite da fusão: **a busca híbrida não é uma rede de segurança garantida**. Ela ajuda quando o acerto lexical do BM25 é forte o bastante para sobreviver à normalização conjunta com o denso — como acontecia com o estelionato antes da correção do parser. Mas quando a consulta é uma paráfrase coloquial que não compartilha vocabulário nem com a rubrica nem com o *caput* do dispositivo certo, denso e híbrido podem falhar juntos, e só o léxico puro, isolado, ainda enxerga o sinal.

Avaliação de recuperação

Sobre um conjunto-ouro de 6 perguntas (GoldItem), o retriever denso alcança:

```
hit_rate@5 = 0,833    (5/6)
MRR        = 0,833
```

MRR agora **coincide** com `hit_rate` — o que só acontece quando toda pergunta respondida corretamente acerta o dispositivo certo já na 1ª posição do ranking, não em algum lugar dentro do top-5. Isso é consequência direta do parser rubrica-aware: antes da correção, "furto de coisa alheia móvel" competia de perto com CP:art168 (apropriação indébita) por não ter a rubrica "Furto" reforçando o `embed_text` de CP:art155, o que empurrava o rank do dispositivo certo para baixo mesmo quando ele

ainda aparecia no top-5 (o mesmo caso "155-vs-168" discutido na seção anterior). Hoje CP:art155 lidera com folga (0,890 contra 0,878 de CP:art168), e as cinco perguntas dentro do escopo do corpus — homicídio, furto, roubo, porte de drogas e associação para o tráfico — acertam todas o rank 1.

A única falha é uma pergunta deliberadamente fora de escopo ("*Homicídio culposo na direção de veículo automotor*", esperando CTB:art302 — o Código de Trânsito não faz parte do corpus); como VectorIndex.query sempre devolve os *k* vizinhos mais próximos (não há limiar de abstenção nesta camada), a consulta retorna os artigos do CP/L11343 mais próximos semanticamente (sobre culpa, trânsito, condução), mesmo sabendo que nenhum é a resposta certa — um limite estrutural do design, não um erro de embedding, e inalterado pelo fix. A notebook observa que recuperação por *k* fixo não distingue "não sei" de "a melhor opção que tenho"; esse problema é tratado à parte pela camada de geração, com verificação de citação e abstenção (seção seguinte).

Estratégia de inferência local ou remota (c04)

A notebook c04_inferencia_local_ou_remota.ipynb mede a inferência local, arquiteta (sem executar) um baseline em nuvem, e propõe a arquitetura de produção recomendada.

Justificativa de privacidade, custo e latência

A escolha por geração **local**, via Ollama, é justificada primeiro por privacidade: consultas sobre Direito Penal podem envolver detalhes de casos reais (fatos, nomes, contexto de uma situação concreta que alguém está tentando entender). Rodando inteiramente na máquina — modelo, prompt, geração — nenhum dado trafega pela rede nem passa por terceiro. Sob a LGPD (Lei 13.709/2018), isso elimina de saída toda a superfície de risco associada a compartilhar dados pessoais/sensíveis com um processador externo.

Latência medida (local)

Três chamadas reais e cronometradas ao llama3.1:8b — uma pergunta de prosa curta, uma de prosa comparativa mais longa (furto vs. roubo) e uma com saída JSON estruturada (schema com campos resposta/artigo) — produziram:

Chamada	Latência
Prosa curta	2,21 s
Prosa longa (comparação)	2,56 s
JSON estruturado	3,46 s
Média (3 chamadas)	2,74 s

Nenhuma dessas chamadas passou pela verificação de citação do RAG (rodaram "peladas", sem fundamentação) — o exemplo de saída JSON, aliás, evidencia por que fundamentação importa: o modelo trocou os valores das chaves "resposta" e "artigo" entre si, um erro de conteúdo que o schema por si só não impede.

Baseline em nuvem — arquitetado, não executado

LLMClient é definido como um Protocol (tipagem estrutural), e um CloudClient esqueleto satisfaz esse protocolo sem exigir nenhuma chave de API commitada ou lida do ambiente (OPENAI_API_KEY verificada como ausente, de propósito). A comparação de qualidade/custo/latência para a nuvem é, portanto, **raciocinada, não medida** — e o relatório é transparente sobre essa distinção:

Critério	Local (Ollama, llama3.1:8b)	Nuvem (API)	Nuvem privada (self-hosted, VPC)
Privacidade	Máxima — nenhum dado sai da máquina	Dados trafegam para o provedor, sujeitos à política de retenção dele	Alta — dados ficam na VPC própria
Qualidade	Boa para respostas fundamentadas em RAG; modelo 8B tem limites de raciocínio fora do recuperado	Geralmente superior (<i>estimativa raciocinada</i>)	Configurável, conforme GPU disponível (<i>estimativa raciocinada</i>)
Custo	Sem custo por chamada (hardware amortizado)	Por token, escala com volume (<i>estimativa raciocinada</i>)	Infraestrutura de GPU, custo fixo maior, marginal zero (<i>estimativa raciocinada</i>)
Latência	Medida: 2,74 s em média	Rede + fila do provedor somam-se à inferência (<i>estimativa raciocinada</i>)	Depende do dimensionamento da VPC (<i>estimativa raciocinada</i>)
Controle	Total	Baixo — dependente do provedor	Alto — mesma interface LLMClient

Recomendação de produção

A conclusão não escolhe um extremo: para este projeto, hoje, a inferência **local** é a escolha certa (latência de poucos segundos, custo marginal zero, nenhum dado sai da máquina). Para um cenário de produção com múltiplos usuários, a recomendação é uma **nuvem privada com pesos abertos** — llama3.1 ou modelo maior, servido via vLLM ou Ollama dentro de uma VPC sem endpoint público, com residência de dados no Brasil (LGPD) e sem logging de terceiros — descrita como uma troca de backend do mesmo LLMClient, não uma reescrita do pipeline.

O pipeline RAG: descrição, exemplos e análise de falhas (c05)

A notebook c05_rag_pipeline.ipynb exercita direito_dados.generation.rag.answer_question de ponta a ponta: recuperação (top-k de dispositivos em vigor) → prompt com ids citáveis → geração local (llama3.1:8b) → saída JSON estruturada → verificação de citação → abstenção quando não há

base. O índice usado cobre apenas o Código Penal (431 dispositivos, indexado em 13,3s).

Caso positivo: peculato

Pergunta: "Qual a pena para o funcionário público que se apropria de dinheiro público em razão do cargo?"

```
recuperados: ['CP:art312', 'CP:art313', 'CP:art327']
citações:    ['CP:art312'] | alucinadas: []
abstained:   False
resposta:    "O funcionário público que se apropria de dinheiro público em razão do
cargo é punido com reclusão de 2 a 12 anos e multa."
```

O sistema cita exatamente o dispositivo correto (peculato, art. 312), sem citação alucinada, e a pena declarada está correta.

Análise de falha honesta: furto (a falha migrou da recuperação para a geração)

O caso mais instrutivo do projeto continua sendo uma falha real, não construída — mas seu perfil mudou depois do parser rubrica-aware, e a notebook narra explicitamente esse antes/depois. O caput do furto (art. 155, "Subtrair, para si ou para outrem, coisa alheia móvel") compartilha vocabulário quase literal com apropriação indébita (art. 168) e roubo (art. 157, "Subtrair coisa móvel alheia... mediante grave ameaça") — três crimes patrimoniais distintos que colidem no mesmo bairro semântico. Antes do fix, essa colisão já derrubava o rank 1 na própria recuperação (o caso "155-vs-168" citado no commit do parser). Hoje a recuperação **acerta**:

```
Recuperação (somente similaridade), "furto de coisa alheia móvel":
CP:art155  score=0.890  'Subtrair, para si ou para outrem, coisa alheia móvel...'  <- cor
CP:art168  score=0.878  'Apropriar-se de coisa alheia móvel...'
CP:art157  score=0.877  'Subtrair coisa móvel alheia... mediante grave ameaça...'
```

Só que a recuperação corrigida não elimina a falha — ela a **empurra para a etapa de geração**. Com os três dispositivos certos no contexto, nessa ordem, `answer_question` ainda erra:

```
recuperados: ['CP:art155', 'CP:art168', 'CP:art157']
citações:    ['CP:art157'] | alucinadas: []
resposta:    "Sim"
```

`hallucinated_citations` fica **vazio**: CP:art157 existe de fato no corpus e foi de fato recuperado — não é uma citação inventada, é uma citação **semanticamente incorreta**, e o modelo a escolheu apesar de CP:art155 (o dispositivo correto) estar em primeiro lugar no próprio contexto que recebeu. Um segundo sintoma agrava o caso: como a consulta é uma frase nominal ("furto de coisa alheia móvel"), não uma pergunta, a resposta gerada foi apenas "Sim" — uma confirmação de uma palavra só, sem pena, sem elemento do tipo, sem valor informativo, mas ainda assim "válida" pelo schema (não abstém, não alucina id).

O limite honesto do projeto é hoje mais preciso do que antes do fix: **a correção rubrica-aware resolveu a ambiguidade na camada de recuperação, mas não resolve — porque não pode resolver, por**

construção — erros da camada de geração, onde o modelo local ainda pode escolher o dispositivo errado entre candidatos já corretamente ordenados. `hallucinated_citations` continua confirmando apenas que o id citado existe no corpus, não que é o id certo para a pergunta nem que a resposta tem conteúdo útil — a principal motivação remanescente para comparar com um baseline em nuvem no relatório técnico.

RAG vs. sem RAG (memória paramétrica)

Para a pergunta *"Qual a pena para quem mata alguém, segundo o Código Penal brasileiro?"*, a resposta **sem RAG** (o mesmo `llama3.1:8b`, sem nenhum contexto recuperado) fabrica conteúdo com aparência de precisão:

"O crime de homicídio é punido com pena de reclusão, que varia de 6 a 20 anos, nos termos do artigo 121, caput, combinado com o artigo 122, ambos da Lei nº 9.455/1997 (Código Penal Brasileiro). [...] Homicídio doloso, qualificado por motivo fútil. Pena: reclusão de 6 (seis) a 20 anos. [...] Homicídio culposo ou impróprio, também conhecido como acidente de trânsito [...] a pena pode ser até dois anos em regime aberto ou especial."

Vários erros passam despercebidos sem verificação: o modelo atribui o art. 121 à **Lei nº 9.455/1997** (a Lei de Tortura — nada a ver com o Código Penal, que é o Decreto-Lei 2.848/1940) e o combina indevidamente com o **art. 122** (induzimento ao suicídio, um crime distinto); ao descrever o homicídio qualificado, repete a pena do *caput* ("6 a 20 anos") quando a pena real do homicídio qualificado é de doze a trinta anos; e inventa, para o homicídio culposo, uma pena "até dois anos em regime aberto ou especial" — a pena real é detenção de um a três anos, sem menção a regime no próprio artigo. Sem RAG, não há nenhum mecanismo para pegar esse tipo de erro.

Com RAG, a resposta cita apenas um id — `CP:art211` ("Destruir, subtrair ou ocultar cadáver ou parte dele", um crime completamente diferente de matar alguém) — e afirma **"reclusão de 20 a 40 anos"**:

```
--- Com RAG (fundamentado no corpus) ---
reclusão de 20 a 40 anos
citações verificadas: ['CP:art211'] | alucinadas: []
```

Esse número não é inventado: existe literalmente no corpus, no § 2º-D do próprio art. 121 (homicídio doloso cometido por integrante de organização criminosa ultraviolenta) — mas é a pena de uma qualificadora bem específica, não a pena geral de homicídio, e **não está no artigo citado** (`CP:art211`). `CP:art211` foi de fato o segundo dispositivo recuperado (score 0,853, atrás de `CP:art121` em 0,877) — um vizinho semântico plausível por vocabulário (morte/cadáver), mas de um crime distinto. `hallucinated_citations` ficou vazio porque `CP:art211` existe no corpus — a verificação de id não pega esse erro, porque o id é real; ela só não garante que o conteúdo gerado corresponde ao dispositivo citado. A lição, que se tornou o argumento central deste relatório sobre confiabilidade: **a verificação de citação garante que o id existe e foi de fato recuperado, não que o texto gerado sobre aquele id é factualmente correto, nem que é o dispositivo certo entre os recuperados** — verificação de id é condição necessária, não suficiente.

Segurança de vigência dentro do RAG

Repetindo o teste da seção de embeddings, mas agora através do pipeline completo: para *"violação sexual mediante fraude"* (que corresponde ao antigo art. 214, revogado pela Lei 12.015/2009 e sucedido por CP:art215), o RAG recupera ['CP:art215', 'CP:art203', 'CP:art273', 'CP:art179', 'CP:art298']; CP:art214 **não aparece** entre os cinco primeiros nem mesmo com `exclude_revoked=False`. Diferente de execuções anteriores desta notebook, essa consulta deixou de exercitar o filtro: com a rubrica correta ("Violação sexual mediante fraude") realocada para CP:art215 pelo parser rubrica-aware, o `embed_text` de CP:art214 é hoje só o carimbo de revogação, sem sinal semântico competitivo — CP:art215 lidera as duas listas (filtrada e não filtrada) com score 0,892, idênticas entre si. A garantia estrutural continua válida (o filtro `exclude_revoked=True` é aplicado **antes** da consulta vetorial, não depois — nenhum dispositivo revogado chega ao contexto do modelo, independentemente do score que teria), só não é mais **necessária** para este caso de teste específico.

A notebook não localiza, nesta execução, nenhuma consulta do Código Penal em que um artigo revogado ainda vença os vigentes/alterados relacionados — o que é boa notícia sobre o corpus, mas enfraquece este exemplo como demonstração do filtro em ação. A demonstração viva atual do filtro em funcionamento é outra: para a consulta *"adultério é crime?"*, CP:art240 (adultério, revogado pela Lei 11.106/2005) **lidera** o ranking bruto sem filtro (score 0,874, o maior de todos) e desaparece completamente do top-5 com `exclude_revoked=True` (padrão) — verificado diretamente contra o índice fora desta notebook, com o mesmo par de chamadas `index.query(..., exclude_revoked=True/False)` usado nas demais seções.

Abstenção em pergunta fora de escopo

Pergunta deliberadamente irrelevante: *"Qual a receita de bolo de cenoura?"*. O índice sempre retorna os *k* vizinhos mais próximos (não há corte de relevância na camada de recuperação), mas o modelo, seguindo o `SYSTEM_PROMPT`, reconhece que nada nas provisões recuperadas responde à pergunta:

```
abstained: True
citations: []
resposta: "A pergunta não está relacionada às provisões fornecidas."
```

Verificação de citação alucinada — demonstração forçada

Nos testes reais das seções anteriores, o modelo local honesto **não produziu nenhuma citação alucinada**. Para demonstrar o mecanismo de verificação mesmo assim, a notebook injeta um FakeLLM programado para citar um id inexistente:

```
{"answer": "Resposta fabricada citando um artigo inexistente.",
 "citations": ["CP:art999", "CP:art121"], "abstained": false, "confidence": 0.95}
```

```
citações verificadas: ['CP:art121']
citações alucinadas: ['CP:art999']
```

CP:art999 é sinalizado e excluído mesmo com `abstained: false` e `confidence: 0.95` afirmados pelo modelo — a verificação é puramente programática (checagem de pertencimento a um conjunto de ids válidos), independente de quão convincente a alucinação pareça.

Detecção de antinomias: princípios, adjudicação e avaliação (c06)

A notebook `c06_antinomias.ipynb` implementa a contribuição mais original do projeto: um detector de **candidatos** a antinomia (conflito normativo) em três etapas, sobre o Código Penal (431 dispositivos indexados, dos quais 406 em vigor).

Pipeline em três etapas

1. **Geração de candidatos por similaridade** (`generate_candidates`, `k=3`, limiar de similaridade `0,85`): dos 431 dispositivos do CP indexados, 406 estão em vigor (os 25 restantes, revogados, são excluídos desta etapa). A comparação exaustiva desses 406 dispositivos vigentes seria ~82 mil pares ($406 \times 405 / 2$); o filtro por similaridade reduz o espaço a **813 pares** acima do limiar — ainda demais para adjudicar todos com um LLM local em tempo de notebook, mas tratável para o subconjunto de maior similaridade levado à etapa seguinte.
2. **Princípios LINDB — determinísticos onde possível, LLM onde exige leitura semântica.** *Lex superior* (hierarquia) e *lex posterior* (data) são computáveis a partir de metadados, sem LLM. *Lex specialis* (qual norma é mais específica) exige comparar conteúdo, e fica a cargo do adjudicador LLM local, que recebe uma "dica" determinística sempre que aplicável.
3. **Avaliação** (`evaluate_antinomias`) contra um *gold set* pequeno e declaradamente ilustrativo — precisão, revocação e F1.

Adjudicação dos 12 candidatos de maior similaridade

Por custo computacional, a adjudicação com LLM é limitada aos 12 pares de maior similaridade (todos entre 0,893 e 0,906, liderados por CP:art210 × CP:art211, sobre violação de sepultura). Desses 12, **9 foram confirmados** como conflito candidato, majoritariamente por *lex specialis* (confiança entre 0,80 e 1,00); **3 foram rejeitados** (CP:art198×CP:art199, CP:art296×CP:art306, CP:art359-0×CP:art359-Q) — o modelo julgou sem conflito plausível ou com confiança abaixo do limiar (`min_confidence=0,5`). A taxa de confirmação (75%) ainda é consistente com o padrão esperado (a geração já filtrou por similaridade temática altíssima), mas a rejeição de uma fração não trivial mostra que a adjudicação **não é um mero carimbo**: ela agrega julgamento além do que o limiar de similaridade sozinho capturaria. Um exemplo confirmado, com justificativa textual do próprio LLM:

```
CP:art213 × CP:art217-A | princípio=lex_specialis confiança=0.80
razão: "As leis têm a mesma hierarquia e data, então aplicamos a regra da
lex specialis, que prioriza a norma mais específica."
```

Todos os pares confirmados geram uma aresta `conflict_candidate` no grafo, com `verification_state=CANDIDATE` — nunca um veredito.

Avaliação contra o gold set

O *gold set* (3 pares, escolhidos e justificados pelo autor, não validados por especialista — limitação declarada explicitamente) cobre três famílias de conflito plausível: estupro vs. estupro de vulnerável (art. 213 × art. 217-A), atentado contra a liberdade de trabalho vs. constrangimento a celebrar contrato (art. 197 × art. 198), e a família de crimes de aborto (art. 124 × art. 126). As métricas resultantes:

```
precisão: 0,333 (tp=3, fp=6)
revocação: 1,000 (tp=3, fn=0)
F1: 0,500
```

Nesta execução, os três pares do gold set sobreviveram **as duas etapas**: caíram entre os 12 candidatos de maior similaridade e foram confirmados pela adjudicação — recall perfeito (1,000). A precisão continua baixa (0,333): dos 9 conflitos candidatos confirmados, 6 não estão no gold set minúsculo de 3 itens. Isso **não** significa que esses 6 pares sejam falsos positivos no sentido jurídico — são candidatos igualmente plausíveis que simplesmente não foram incluídos neste gold set ilustrativo; com um denominador dessa ordem de grandeza, a precisão numérica é estruturalmente baixa por construção, não porque o detector erre sistematicamente. O recall perfeito, por sua vez, é uma propriedade **desta execução**, não uma garantia estrutural do pipeline: em outra rodada, ou com `k/threshold` diferentes na etapa de geração, um par do gold set poderia perfeitamente cair fora do top-12 e nunca chegar à adjudicação — o funil de similaridade/limiar determina o teto de recall antes mesmo do LLM entrar em cena. Um gold set maior (~15 pares) verificado por um especialista em direito penal continua sendo trabalho futuro declarado, não uma lacuna escondida.

Análise "a lei como dado" (c07)

A notebook `c07_lei_como_dado.ipynb` trata o microssistema penal como um **grafo com proveniência**, não apenas como texto. Nós são normas (`NORM`) e dispositivos (`PROVISION`); arestas `AMENDS/REVOKES` são extraídas diretamente das anotações inline do Planalto ((Redação dada por...), (Incluído por...), (Revogado por...)) — fatos verificados do texto oficial (`verification_state=VERIFIED`, `confidence=1.0`).

Estrutura do grafo


Sobre o corpus completo (9 normas, 2.310 artigos), o grafo tem:

```
Nós: 2.381 (337 NORM + 2.044 PROVISION)
Arestas: 4.727 (4.453 AMENDS + 274 REVOKES)
```

Sobre o subgrafo do Código Penal isoladamente: **979 arestas AMENDS + 47 REVOKES** (1.026 arestas no total), sobre 525 nós ao incluir as normas externas que o emendaram.

Linha do tempo de emendas

O gráfico de barras abaixo (`report/figures/decades.png`) mostra o total de alterações/revogações do microssistema por década, agregado a partir das arestas `AMENDS/REVOKES` do grafo completo:



1940: 26	1950: 16	1960: 15	1970: 49	1980: 268
1990: 422	2000: 1.283	2010: 1.199	2020: 970	

Dois picos concentram a maior parte da narrativa:

- **1984 (261 das 268 alterações da década, todas no CP): a reforma da Parte Geral do Código Penal** (Lei 7.209/1984) — a maior reescrita estrutural do CP desde 1940, introduzindo o sistema atual de aplicação de pena, regimes de cumprimento e circunstâncias atenuantes/agravantes. O grafo captura isso como um único evento em massa concentrado em um ano.
- **2019 (548 alterações — o maior pico anual do corpus):** não é um evento único, mas a sobreposição de pelo menos três reformas simultâneas de grande porte, visível no *breakdown* por norma (L11343: 223, CPP: 150, CF: 72, CP: 40, LEP: 30, L11340: 19, L8072: 14): o **Pacote Anticrime** (Lei 13.964/2019, concentrado em CPP e CP), a **Reforma da Previdência** (EC 103/2019, concentrada na CF) e uma extensa reforma da **Lei de Drogas** quanto à apreensão e destinação de bens (Lei 13.840/2019). Nenhuma norma isolada explica o pico sozinha.

Olhando apenas o Código Penal, a mesma agregação por década mostra um padrão semelhante, com o pico de 1984 ainda mais nítido em proporção: 1960: 5, 1970: 2, 1980: 265, 1990: 95, 2000: 192, 2010: 145, 2020: 294.

Vigência derivada em nível de artigo


Um ponto de design deliberado do parser (`direito_dados/corpus/annotations.py`, função `article_status`) é que a vigência de um artigo é derivada **apenas da anotação sobre o próprio caput**, não de qualquer anotação em qualquer parágrafo do artigo:

```
def article_status(caput, annotations):
    """Article-level vigência: REVOGADO only if the caput itself is revoked;
    ALTERADO if the article was otherwise touched; else VIGENTE."""
```

Essa é uma correção intencional de um erro fácil de cometer: se um único parágrafo de um artigo grande for revogado, o artigo inteiro **não** deve ser marcado como revogado — ele continua em vigor, apenas alterado. Sem essa distinção artigo-a-artigo, dispositivos amplamente citados (como o próprio art. 121, homicídio, que teve parágrafos alterados ao longo de décadas) correriam o risco de ser classificados incorretamente como revogados por causa de uma única anotação de revogação em um parágrafo específico. Essa é exatamente a mesma lógica que sustenta o filtro `exclude_revoked=True` da recuperação (seção de embeddings): sem granularidade artigo-a-artigo, o filtro de vigência ficaria grosseiro demais para ser confiável.

No CP, 25 artigos estão de fato revogados (caput revogado): 185, 189–196, 214, 216, 217, 219–224, 231, 231-A, 232, 240, 279, 281, 350 — um conjunto dominado pelos antigos "crimes contra os costumes" (Título VI original do CP de 1940), majoritariamente revogados pelas Leis 11.106/2005 e 12.015/2009, que reformaram a nomenclatura e a estrutura dos crimes sexuais no Código.

Pirâmide de hierarquia




A distribuição calculada (`hierarchy_distribution`) mostra `{'CONSTITUICAO': 1, 'LEI_ORDINARIA': 8}` — apenas dois níveis visíveis, não porque as 9 normas realmente ocupem só duas posições hierárquicas, mas por um efeito colateral técnico digno de nota: `HierarchyLevel` é um Enum em que `LEI_ORDINARIA`, `DECRETO_LEI` e `MEDIDA_PROVISORIA` compartilham o mesmo valor numérico (3) — corretamente, do ponto de vista de *lex superior* (as três têm o mesmo peso hierárquico entre si). Mas em Python, membros de Enum com valores duplicados viram *aliases* do primeiro nome definido, então `DECRETO_LEI.name` é, na prática, `"LEI_ORDINARIA"`. É por isso que o bucket agrega tanto leis ordinárias propriamente ditas (LEP, L11343, L11340, L8072) quanto decretos-lei pré-1988 com força de lei ordinária (CP, CPP, DL3688, LINDB). Só a CF (nível 1, sem par) aparece isolada — um lembrete de que a representação de dados de um Enum pode esconder uma decisão de modelagem que precisa ser lida no código-fonte, não só no gráfico.

Dispositivos mais alterados

No Código Penal isoladamente, o topo do ranking de alterações é: art. 121 (homicídio, 22) e art. 157 (roubo, 22) empatados, seguidos por art. 129 (lesão corporal, 20), art. 7 (extraterritorialidade, 20) e art. 155 (furto, 18). Os dois crimes contra a pessoa e contra o patrimônio mais centrais do Código foram sucessivamente reformados (Lei dos Crimes Hediondos, Pacote Anticrime, entre outras) para endurecer penas e criar qualificadoras. CP:art171 (estelionato) — o artigo cujo *nomen juris* motivou o parser rubrica-aware (seção de embeddings) — também aparece no top-10 (17 alterações), reforçando que é um dispositivo central e ativamente atualizado, não marginal.

Visualização de rede



A figura acima é o subgrafo do Código Penal (525 nós, 1.026 arestas, limitado a 80 nós para legibilidade) — deliberadamente escolhido em vez do grafo completo (2.381 nós seria ilegível em um único desenho). Nós azuis são **normas** (o próprio CP e as leis que o emendaram ao longo do tempo); nós vermelhos são **dispositivos** (artigos). As arestas convergindo de várias normas emendadoras para os mesmos artigos centrais (homicídio, roubo, furto, estelionato) tornam visível, de forma literal, por que esses dispositivos lideram o ranking de alterações: eles são hubs de grau alto no grafo, não apenas números em uma tabela.

Um detalhe de design vale registro: excluir nós externos (`include_external=False`) deixa 2.053 nós **sem nenhuma aresta** — porque toda aresta AMENDS/REVOKES do corpus tem origem em uma norma emendadora externa às 9 normas do microssistema (ex.: "Lei nº 13.964, de 2019"). Por isso as três figuras deste relatório usam `include_external=True`: sem os nós externos, a estrutura relacional do corpus simplesmente desaparece.

Tratar o microssistema penal como grafo transforma perguntas historicamente respondidas por doutrina e leitura manual — "quando o Código Penal foi mais reformado?", "quais dispositivos são mais instáveis?", "o que realmente aconteceu em 2019?" — em consultas sobre dados: agregações, rankings e uma visualização de rede, todas reproduzíveis a partir do mesmo snapshot versionado em `data/raw/`. É essa mesma estrutura — nós, arestas, proveniência e `verification_state` — que sustenta tanto a segurança de vigência da recuperação quanto o detector de antinomias: "lei como dado" não é uma

metáfora, é a escolha de arquitetura que faz o resto do sistema funcionar.

Quem mudou a lei — autoria de registro (camada adicional, além da rubrica)

O grafo responde *qual lei alterou qual artigo*; esta camada adicional responde **quem propôs cada uma dessas leis**, segundo o registro oficial do Congresso. Para cada uma das **328 normas distintas** que emendaram o corpus (193 leis ordinárias, 125 emendas constitucionais consultáveis, mais casos residuais), um adaptador (`direito_dados/attribution/`) consulta a API de dados abertos do Senado Federal — o serviço `/dadosabertos/processo`, que aceita busca reversa por número/ano/tipo da norma — e extrai o projeto de origem (ex.: PL 10372/2018), a casa iniciadora e a **autoria de iniciativa** (nome, tipo, partido e UF quando parlamentar). Para projetos originados na Câmara com coautoria múltipla, a lista completa de subscritores vem da API da Câmara (`/proposicoes/{id}/autores`), corrigindo a tendência do espelho do Senado de registrar apenas o primeiro autor.

Cobertura obtida (lote executado em 11/07/2026; dataset versionado em `data/attribution/authorship.json`, reconstruível com `make attribution`):

Tipo	Resolvidas	Taxa
Leis ordinárias	186 / 189	98,4%
Emendas constitucionais	123 / 125	98,4%
Ignoradas por tipo (decretos-lei, MP, referências sem ano)	14	registradas como <code>skipped_type</code>
Não encontradas na API	5	registradas como <code>not_found</code>

No grafo, isso materializa **2.344 arestas enacted_by** ligando as leis emendadoras a **1.105 nós de autor**, com proveniência por aresta (`verification_state=VERIFIED`, fonte = o registro do processo consultado). Distribuição por origem: Câmara 138 normas, Senado 92, Poder Executivo 69, comissões (incl. CPMIs) 10.

Um exemplo mostra ao mesmo tempo o valor e o limite do dado: para a **Lei 13.964/2019 ("pacote anticrime")**, a autoria de registro são **11 deputados** (subscritores do PL 10.372/2018 — Aureo, Baleia Rossi, Celso Russomanno, José Rocha e outros) — e **não** o PL 882/2019 do Poder Executivo, popularmente associado à lei, que foi arquivado por prejudicialidade ao ser absorvido pelo substitutivo. O sistema exhibe o que o registro oficial afirma, com a fonte: *autoria de registro*, não narrativa popular.

Limitações declaradas: o partido refletido é a filiação atual/última registrada nas APIs, não necessariamente a da época da autoria; a atribuição é em nível de **lei** (a lei alterou o artigo; os autores propuseram a lei), não de artigo; e, coerente com a postura de transparência do projeto, os dados são apresentados como **proveniência factual** ("a norma X, de autoria de Y, alterou o art. Z"), nunca como atribuição de responsabilidade por eventual conflito normativo. A camada é explorável na aba **"Quem mudou a lei"** da interface web local (`make app`).

Riscos de segurança e controles

O projeto trata segurança não como uma auditoria à parte, mas como uma propriedade de arquitetura: cada risco relevante de um sistema RAG jurídico tem um controle programático correspondente, testado com um caso concreto nas notebooks c02/c03/c05. A tabela abaixo consolida os riscos considerados:

Risco	Controle	Evidência
Injeção de prompt ("ignore as instruções anteriores...")	SYSTEM_PROMPT fixo no código (não construído por concatenação de entrada do usuário); saída sempre validada por <code>parse_answer/schema</code> ; citações sempre verificadas contra <code>valid_ids</code>	c05: prompt de injeção explícito recebido → modelo não vaza o system prompt, não afirma a falsidade solicitada, responde "Não posso cumprir esse pedido." e se abstém (<code>abstained=True</code> , <code>citations=[]</code>)
Vazamento de prompt/contexto	Geração 100% local via Ollama — nada sai da máquina; sem telemetria de terceiros	c04: <code>OPENAI_API_KEY</code> verificada como ausente; nenhuma chamada de rede em nenhuma notebook
Citação alucinada (id inexistente no corpus)	<code>hallucinated_citations</code> — verificação programática de pertencimento contra o conjunto de ids reais, independente da confiança declarada pelo modelo	c05: FakeLLM citando <code>CP:art999</code> (inexistente) é corretamente sinalizado e excluído, mesmo com <code>confidence: 0.95</code>
Alucinação de validade (citar lei revogada como se estivesse em vigor)	Filtro <code>exclude_revoked=True</code> na recuperação, aplicado antes da consulta vetorial (não é efeito colateral do ranking); vigência derivada em nível de artigo, não de norma inteira	c03: <code>CP:art185</code> (revogado) tem o maior score de similaridade bruta (0,914) mas nunca aparece nas respostas com o filtro padrão; c05: <code>CP:art240</code> (adultério, revogado) lidera o ranking bruto sem filtro (0,874) e desaparece completamente com o filtro padrão
Resposta fabricada sem base normativa	Abstenção instruída no <code>SYSTEM_PROMPT</code> ; se não há resultados recuperados, o sistema se abstém sem sequer chamar o modelo	c05: pergunta fora de escopo ("receita de bolo de cenoura") → <code>abstained=True</code> , <code>citations=[]</code>
Saída malformada / injeção via formatação	JSON schema (<code>format=<schema></code> nativo do Ollama) restringindo a estrutura da saída; <code>parse_answer</code> tolerante a cercas de código e prosa ao redor, mas falha para o lado seguro (abstenção) se não houver JSON balanceado parseável	c02: técnica 1 (zero-shot) demonstra a falha que o schema resolve; c05 confirma o comportamento em produção

Higiene de segredos	Nenhuma chave de API necessária para o caminho de produção (Ollama local, sem autenticação, localhost:11434); nenhum segredo no repositório	README, c04
---------------------	---	-------------

O ponto central, reafirmado em mais de uma notebook, é que **a segurança deste RAG não depende de o modelo "se comportar bem"** — depende de camadas de verificação programática que não confiam nele: o filtro de vigência roda antes da consulta vetorial, a verificação de citação roda depois da geração, e a abstenção é o padrão seguro em ambas as pontas. Nenhuma dessas garantias é formal ou impenetrável a um adversário mais sofisticado do que os testados (não há *sandboxing* real do modelo), mas cada uma delas transforma uma falha silenciosa em uma falha detectável.

Interpretação dos resultados

Lidos em conjunto, os sete capítulos contam uma história consistente sobre onde um LLM de 8B parâmetros, servido localmente, é confiável e onde não é:

Conhecimento paramétrico jurídico é raso — RAG não é opcional, é a premissa do projeto. Desde o capítulo 1 (BERTimbau falha em prever "móvel" no cloze de furto) até o capítulo 5 (a resposta sem RAG para a pena de homicídio atribui o art. 121 à Lei de Tortura, funde-o com o art. 122 e erra a pena da qualificadora), a evidência é consistente: sem fundamentação em texto recuperado, o modelo produz prosa fluente e convincente que é factualmente incorreta. A arquitetura do projeto — RAG hierarquia- e vigência-aware, com verificação de citação obrigatória — é uma resposta direta a esse achado, não uma escolha de design arbitrária.

Verificação de citação captura um tipo de erro, não todos — e o parser rubrica-aware isolou esse limite na camada de geração. O caso do furto (capítulo 5) é o achado mais importante do projeto sobre os limites do que já foi construído: depois do fix, a recuperação acerta CP:art155 em 1º lugar, mas a geração ainda cita CP:art157 (roubo) — o erro sobreviveu ao contexto correto. O caso do homicídio com RAG é ainda mais nítido: a resposta cita apenas CP:art211 (crime de ocultação de cadáver, não homicídio) e afirma "reclusão de 20 a 40 anos" — um número real do corpus (art. 121 §2º-D), mas atribuído ao artigo errado. hallucinated_citations garante que todo id citado *existe e foi recuperado* — mas não garante que o conteúdo gerado sobre aquele id responde corretamente à pergunta nem que é o dispositivo certo entre os recuperados. Verificação de existência e verificação de correção são propriedades diferentes, e só a primeira está implementada.

A busca híbrida ajuda, mas não é uma rede de segurança garantida. Antes do parser rubrica-aware, o caso do art. 171 (estelionato) mostrava embeddings semânticos perdendo um dispositivo cujo nome popular não estava no texto indexado, com o BM25 (léxico puro) resgatando o acerto. Hoje esse caso está corrigido — a rubrica presa ao artigo faz o denso liderar sozinho. Mas uma paráfrase coloquial da apropriação indébita ("*ficar com um dinheiro que recebeu emprestado e não devolver*", sem usar a rubrica "Apropriação indébita" nem o vocabulário do *caput*) escapa do denso inteiramente (ausente até no top-20) e do híbrido: a normalização min-max de hybrid_search zera o componente denso quando o artigo está fora do pool, o que reduz pela metade sua pontuação

combinada — mesmo o BM25 encontrando o artigo certo (rank 4) isoladamente. A fusão híbrida é uma rede de segurança condicional, não universal.

A separação entre determinístico e semântico é o que torna o detector de antinomias auditável. *Lex superior* e *lex posterior* nunca dependem do LLM — são cálculo sobre hierarquia e data, sempre reproduzíveis e sempre corretos dado o metadado de entrada. Só *lex specialis*, que exige julgamento sobre o conteúdo de dois textos, é delegado ao modelo, que nesta execução rejeitou 3 dos 12 candidatos adjudicados (25%) — evidência de que a etapa agrega julgamento, não apenas ratifica o limiar de similaridade. A precisão baixa (0,333) do gold set de 3 pares não é evidência de que o detector erra sistematicamente — é uma consequência aritmética de comparar 9 candidatos confirmados contra um gold set propositalmente minúsculo; a revocação perfeita (1,000) nesta execução é uma propriedade do resultado observado, não uma garantia estrutural do pipeline — o funil de geração de candidatos (limiar de similaridade) segue sendo o teto de recall antes mesmo do LLM entrar em cena.

A estrutura do grafo explica, de forma legível, por que certos dispositivos são "instáveis". Os artigos que lideram o ranking de alterações (homicídio, roubo, furto, estelionato) são exatamente os mesmos que aparecem nos casos de falha de recuperação e nas notícias de reforma penal recorrente (Lei dos Crimes Hediondos, Pacote Anticrime) — a análise "direito como dado" não é decorativa, ela explica *por que* esses dispositivos específicos são os pontos de atrito do sistema inteiro, do parser à geração.

Em síntese: o projeto não afirma ter resolvido a confiabilidade de RAG jurídico — afirma ter **medido** onde ela funciona (fundamentação, verificação de existência de citação, filtro de vigência) e onde ainda falha (precisão semântica de conteúdo, cobertura de vocabulário puramente denso, gold sets pequenos), com evidência concreta e reproduzível para cada uma dessas afirmações.

Síntese em linguagem não técnica

Em termos simples: o projeto pega nove leis penais brasileiras (Constituição, Código Penal, Código de Processo Penal, entre outras) e as transforma em algo que um computador pode "conversar" sobre — sem nunca dizer a alguém se ele está ou não cometendo um crime, apenas ajudando a encontrar e entender o texto da lei relevante.

Primeiro, testamos se um modelo de linguagem "sabe" direito penal de cabeça, sem consultar nada — e descobrimos que não sabe muito bem: ele erra até o nome de um dos elementos centrais do crime de furto. Isso confirma que a estratégia certa não é confiar na memória do modelo, e sim **buscar o texto da lei relevante primeiro e só então gerar uma resposta baseada nesse texto** — a técnica chamada de RAG (geração aumentada por recuperação).

Testamos três formas de pedir ao modelo para responder de forma organizada, até chegar a uma que sempre produz uma resposta estruturada, com a lista exata de artigos usados. Construímos um buscador que entende perguntas em português comum ("quem mata alguém") e as conecta ao artigo certo do Código Penal, mesmo quando a pergunta não usa o mesmo vocabulário técnico da lei. No caminho, encontramos e corrigimos um defeito real na forma como o texto da lei era dividido: o nome oficial de cada crime ("Furto", "Estelionato") estava sendo colado no artigo errado, o que prejudicava

justamente as buscas por nome de crime — depois do conserto, essas buscas passaram a acertar de cara. Mesmo assim, descobrimos um caso em que a busca "por significado" ainda falha e uma busca "por palavra exata" (mais simples) ainda ajuda, então usamos as duas juntas — embora nem sempre a combinação salve o dia.

Rodamos o modelo inteiramente no computador local, não na nuvem — porque perguntas sobre casos jurídicos podem envolver informação sensível, e local nenhum dado sai da máquina. Medimos: cada resposta leva cerca de 2,7 segundos.

Construímos um sistema que responde perguntas citando os artigos exatos usados, e que verifica automaticamente se cada citação existe de verdade na lei — se o modelo "inventasse" um artigo que não existe, o sistema pega esse erro. Descobrimos, porém, um limite importante que nem o conserto da busca resolveu: o sistema garante que o artigo citado existe, mas não garante que o artigo citado é o certo para aquela pergunta — mesmo depois de a busca passar a entregar o artigo certo em primeiro lugar, em um teste o modelo ainda confundiu furto com roubo ao gerar a resposta, e em outro citou um artigo sobre ocultação de cadáver ao responder sobre a pena de homicídio.

Também construímos um "detector de contradições": ele procura pares de artigos que podem estar em conflito e tenta explicar, usando regras clássicas do direito (a lei mais nova vale mais que a mais antiga, a lei mais específica vale mais que a genérica), qual prevaleceria. Mas nunca emite um veredito — apenas uma sugestão para um humano revisar.

Por fim, tratamos a lei toda como uma rede de conexões — quais leis alteraram quais artigos, e quando — para descobrir, por exemplo, que 1984 e 2019 foram os anos de maior reforma do Código Penal, e quais artigos (homicídio, roubo, furto) são os mais "mexidos" ao longo da história.

Limitações

- **Vigência tácita e inconstitucionalidade ficam fora do escopo determinístico.** O sistema deriva vigência das anotações explícitas do Planalto; revogação tácita (uma norma nova contradizendo silenciosamente uma antiga, LINDB art. 2º §1º) e inconstitucionalidade declarada pelo STF não têm anotação correspondente e não são detectadas.
- **Hierarquia com aliasing de Enum.** Decreto-lei, lei ordinária e medida provisória compartilham o mesmo valor numérico de hierarquia (posição 3) por serem tratados como equivalentes para fins de *lex superior* — correto substantivamente, mas isso faz a pirâmide de hierarquia (c07) exhibir apenas dois níveis visíveis em vez de seis, um efeito colateral técnico que precisa ser lido no código, não só no gráfico.
- **Citação verificada garante existência, não correção — mesmo com recuperação perfeita.** O caso do furto (c05) demonstra isso da forma mais direta possível: depois do parser rubrica-aware corrigir a recuperação (CP:art155 passa a liderar com folga), a geração ainda citou CP:art157 (roubo). O caso do homicídio com RAG é mais grave ainda: a resposta citou CP:art211 (ocultação de cadáver, não homicídio) e atribuiu a ele uma pena — "20 a 40 anos" — que existe de fato no corpus (art. 121 §2º-D), mas em outro dispositivo. `hallucinated_citations` vazio garante apenas que o id citado existe e foi recuperado; não garante que é o id certo nem que o conteúdo gerado sobre ele é correto. Esta é hoje a fragilidade mais séria e mensurável do pipeline — não mais compartilhada com a recuperação, isolada na camada de geração.

- **A fusão híbrida (BM25 + denso) não é uma rede de segurança universal.** A normalização min-max de `hybrid_search` zera o componente denso de um dispositivo ausente do seu pool de candidatos, o que pode afundar sua pontuação combinada mesmo quando o BM25, isoladamente, o encontra (caso real: paráfrase coloquial de apropriação indébita, BM25 rank 4, híbrido fora do top-5). A fusão ajuda quando o acerto lexical é forte o bastante para sobreviver à normalização conjunta — não em todos os casos.
- **Cobertura de rubrica é parcial, por natureza do próprio corpus.** O parser rubrica-aware extrai 423 rubricas em um corpus de 2.310 artigos — a maioria dos artigos genuinamente não tem uma (só artigos que abrem um tipo penal novo carregam *nomen juris* explícito no Planalto), e o formato de anotação do CPP difere do CP o suficiente para que a extração de rubrica, calibrada sobre o CP, não generalize automaticamente para todas as normas do corpus.
- **Modelo local de 8B parâmetros erra em conteúdo, mesmo com contexto correto e corretamente ordenado.** Em mais de um teste (c02, c04, c05), o `llama3.1:8b` produziu conteúdo impreciso (penas erradas, dispositivos trocados, fontes legais fabricadas) mesmo recebendo o texto legal correto como contexto — a motivação central para comparar com um baseline em nuvem, arquitetado mas não executado neste projeto.
- **Baseline em nuvem não foi medido, apenas arquitetado.** A comparação de qualidade/custo/latência com um provedor de nuvem (c04) usa estimativas raciocinadas, não chamadas reais — uma limitação explícita, não uma alegação de equivalência.
- **Gold sets pequenos e não verificados por especialista.** Tanto o gold set de recuperação (6 perguntas) quanto o de antinomias (3 pares) foram autorados pelo próprio autor do projeto, não por um profissional do direito penal — as métricas de precisão/revocação relatadas são ilustrativas do método de avaliação, não uma medida definitiva de qualidade. Nesta execução os 3 pares do gold set de antinomias sobreviveram integralmente às duas etapas (recall 1,000) — uma propriedade desta rodada específica de `k/threshold`, não uma garantia estrutural do pipeline.
- **Adjudicação de antinomias limitada aos 12 pares de maior similaridade.** Por custo/tempo de execução em notebook, apenas os 12 candidatos com maior similaridade dos 813 gerados foram levados ao LLM — o teto de recall é determinado pelo limiar de geração de candidatos, antes mesmo de o LLM entrar em cena.
- **Escopo federal-penal, não generalizável sem reengenharia.** O parser de anotações e a lógica de hierarquia são específicos ao formato de anotação do Planalto e à estrutura de normas do microssistema penal; estender a outros ramos do direito ou a legislação estadual/municipal exigiria trabalho de adaptação, não é plug-and-play.

Trabalho futuro

- **Gold set de antinomias expandido e verificado por especialista** (~15 pares, conforme a especificação de design do projeto), permitindo métricas de precisão/revocação estatisticamente mais confiáveis.
- **Baseline em nuvem executado** (não apenas arquitetado), com medição real de latência, custo por token e taxa de acerto de conteúdo em comparação com o modelo local de 8B.
- **Deteção de revogação tácita**, ao menos como candidato heurístico (ex.: dois dispositivos de igual hierarquia tratando da mesma matéria com datas muito distantes, sinalizados para revisão humana, análogo ao detector de antinomias atual).

- **Ampliação da adjudicação de antinomias além dos 12 pares de maior similaridade**, com paralelização ou *batching* para tornar viável adjudicar a totalidade dos 813 candidatos gerados.
- **Verificação de conteúdo da citação — primeiro estágio já implementado.** A técnica *quote-then-answer* foi implementada como estágio opcional (`answer_question(..., verify_quote=True)`, ativo na interface web): o schema ganha um campo `trecho_citado`, gerado **antes** da resposta, que obriga o modelo a copiar o excerto literal de sustentação; o excerto é verificado programaticamente contra os textos recuperados, com três vereditos — *verificado* (existe no dispositivo citado), *atribuição incorreta* (existe em outro dispositivo recuperado — exatamente o erro do caso homicídio/art. 211, agora detectável) e *não encontrado* (inclusive excertos vácuos com menos de 10 caracteres). Resultado honesto observado ao vivo: o modelo de 8B raramente produz um excerto literal verificável (tende a colocar o id ou uma palavra solta no campo), de modo que, com este modelo, o mecanismo funciona sobretudo como **portão de humildade** — respostas não ancoradas passam a exibir alerta em vez de um selo verde. Próximos passos: (a) um segundo LLM como juiz de *groundedness*; (b) reduzir *k* de 5 para 3, diminuindo os vizinhos-distratores; (c) o baseline com modelo maior já listado acima, com o qual se espera que o excerto literal passe a verificar positivamente.
- **Extensão do corpus a outros microssistemas** (ex.: direito tributário, trabalhista), testando se a arquitetura (parser de vigência + grafo + RAG + detector de antinomias) generaliza além do penal.
- **Publicação acadêmica.** Conforme a especificação de design do projeto, dois componentes têm potencial de contribuição citável na literatura: o parser de vigência inline do Planalto (redução de "alucinação de validade", termo cunhado no próprio projeto) e o gold set de antinomias penais com resolução por princípios LINDB.

Instruções de reprodução

O projeto usa **Python 3.11+** (fixado em 3.13 via `.python-version`), gerenciado com **uv** (<https://docs.astral.sh/uv/>) e dependências travadas em `uv.lock`. Um `Makefile` autodocumentado (`make help`) encapsula todos os fluxos:

```
# 0. Caminho rápido – um único comando: instala o que faltar (verificando
#     antes de baixar e pulando o que já existe) e abre a interface web
make run

# 1. Instalar as dependências (cria o ambiente a partir do uv.lock)
make setup

# 2. Demonstração de ponta a ponta – corpus, análises e busca citada
#     (funciona sem Ollama; a etapa de geração é pulada com aviso)
make demo

# 3. (Opcional) Modelos locais: llama3.1:8b via Ollama (~4,9 GB) +
#     embeddings multilingual-e5-base (~440 MB). Requer o Ollama
#     instalado (https://ollama.com) e ativo (ollama serve ou o app).
make models

# 4. Fazer uma pergunta ao RAG
make ask q="qual a pena para furto?"
```



```
# 5. Rodar a suíte de testes (169 testes; os que dependem do modelo e5 real
# ou de um Ollama ativo são pulados automaticamente se indisponíveis)
make test

# 6. (Opcional) Rebaixar o corpus diretamente do Planalto
# (um snapshot já processado acompanha o repositório em data/raw/)
make data

# 7. Re-executar as notebooks (lento; requer Ollama ativo para c02/c04/c05/c06)
make notebooks

# 8. Gerar o relatório em PDF
make report
```

Alternativa sem uv (pip): `python3 -m venv .venv && source .venv/bin/activate && pip install -r requirements.txt && pip install -e .` — em seguida os scripts em `scripts/` e o `pytest` funcionam diretamente.

Após a etapa 8, o PDF é gerado em `report/anderson_correa_sistemas-cognitivos-linguagem-natural_aplicacoes-llms.pdf`. As sete notebooks já estão versionadas **com as saídas calculadas**, de modo que a etapa 7 só é necessária para reexecutar o pipeline do zero — para simples leitura dos resultados, basta abrir as notebooks no GitHub ou localmente com `jupyter lab`.

Observação: o corpus bruto (`data/raw/`) já é versionado no repositório, de modo que a etapa 6 só é necessária para reconstruir os dados diretamente da fonte. As notebooks `c02`, `c04`, `c05` e `c06` fazem chamadas reais a um servidor Ollama local — sem ele ativo, essas células falham (não há *mock* de geração nas notebooks, apenas nos testes unitários).